APRENDIZADO SEMI-SUPERVISIONADO PARA CLASSIFICAÇÃO DE POLARIDADE DE TWEETS

Breno Vieira Arosa

Projeto de Graduação apresentado ao Curso de Engenharia Eletrônica e de Computação da Escola Politécnica, Universidade Federal do Rio de Janeiro, como parte dos requisitos necessários à obtenção do título de Engenheiro.

Orientador: Luiz Pereira Calôba

Rio de Janeiro

Julho de 2017

APRENDIZADO SEMI-SUPERVISIONADO PARA CLASSIFICAÇÃO DE POLARIDADE DE TWEETS

Breno Vieira Arosa

PROJETO DE GRADUAÇÃO SUBMETIDO AO CORPO DOCENTE DO CURSO DE ENGENHARIA ELETRÔNICA E DE COMPUTAÇÃO DA ESCOLA POLITÉCNICA DA UNIVERSIDADE FEDERAL DO RIO DE JANEIRO COMO PARTE DOS REQUISITOS NECESSÁRIOS PARA A OBTENÇÃO DO GRAU DE ENGENHEIRO ELETRÔNICO E DE COMPUTAÇÃO

Autor:

_____

Breno Vieira Arosa

Orientador:

_____

Prof. Luiz Pereira Calôba, Dr. Ing.

Examinador:

_____

Prof Frances Elizabeth Allen, D. Sc.

Examinador:

_____

Prof. Alan Jay Perlis, D. E.

Rio de Janeiro

Julho de 2017

Declaração de Autoria e de Direitos

Eu, *Breno Vieira Arosa* CPF *131.187.117-95*, autor da monografia *Aprendizado Semi-Supervisionado para Classificação de Polaridade de Tweets*, subscrevo para os devidos fins, as seguintes informações:

1. O autor declara que o trabalho apresentado na disciplina de Projeto de Graduação da Escola Politécnica da UFRJ é de sua autoria, sendo original em forma e conteúdo.

2. Excetuam-se do item 1. eventuais transcrições de texto, figuras, tabelas, conceitos e idéias, que identifiquem claramente a fonte original, explicitando as autorizações obtidas dos respectivos proprietários, quando necessárias.

3. O autor permite que a UFRJ, por um prazo indeterminado, efetue em qualquer mídia de divulgação, a publicação do trabalho acadêmico em sua totalidade, ou em parte. Essa autorização não envolve ônus de qualquer natureza à UFRJ, ou aos seus representantes.

4. O autor pode, excepcionalmente, encaminhar à Comissão de Projeto de Graduação, a não divulgação do material, por um prazo máximo de 01 (um) ano, improrrogável, a contar da data de defesa, desde que o pedido seja justificado, e solicitado antecipadamente, por escrito, à Congregação da Escola Politécnica.

5. O autor declara, ainda, ter a capacidade jurídica para a prática do presente ato, assim como ter conhecimento do teor da presente Declaração, estando ciente das sanções e punições legais, no que tange a cópia parcial, ou total, de obra intelectual, o que se configura como violação do direito autoral previsto no Código Penal Brasileiro no art.184 e art.299, bem como na Lei 9.610.

6. O autor é o único responsável pelo conteúdo apresentado nos trabalhos acadêmicos publicados, não cabendo à UFRJ, aos seus representantes, ou ao(s) orientador(es), qualquer responsabilização/ indenização nesse sentido.

7. Por ser verdade, firmo a presente declaração.

_____

Breno Vieira Arosa

UNIVERSIDADE FEDERAL DO RIO DE JANEIRO
Escola Politécnica - Departamento de Eletrônica e de Computação
Centro de Tecnologia, bloco H, sala H-217, Cidade Universitária
Rio de Janeiro - RJ CEP 21949-900

DEDICATÓRIA

Opcional.

AGRADECIMENTO

Sempre haverá. Se não estiver inspirado, aqui está uma sugestão: dedico este trabalho ao povo brasileiro que contribuiu de forma significativa à minha formação e estada nesta Universidade. Este projeto é uma pequena forma de retribuir o investimento e confiança em mim depositados.

RESUMO

Inserir o resumo do seu trabalho aqui. O objetivo é apresentar ao pretenso leitor do seu Projeto Final uma descrição genérica do seu trabalho. Você também deve tentar despertar no leitor o interesse pelo conteúdo deste documento.

Palavras-Chave: trabalho, resumo, interesse, projeto final.

ABSTRACT

Insert your abstract here. Insert your abstract here. Insert your abstract here. Insert your abstract here. Insert your abstract here.

Key-words: word, word, word.

SIGLAS

UFRJ - Universidade Federal do Rio de Janeiro

EMQ - Erro Médio Quadrático

SVM - *Suport Vector Machine*

Sumário

Lista de Figuras

Lista de Tabelas

Lista de Algoritmos

Capítulo 1

Introdução

1.1 Tema

O tema do projeto é o estudo de técnicas de aprendizado de máquina para classificação de sentimento em mensagens de redes sociais, em especial o Twitter. Portanto, o projeto visa criar um modelo capaz de distinguir entre a polaridade, positiva ou negativa, de uma mensagem.

1.2 Delimitação

O objeto de estudo são *tweets*, mensagens publicadas no Twitter. Serão utilizadas duas bases de dados: a primeira, uma base anotada automaticamente pelo *Sentiment140* [2], o qual é formado por um grupo de alunos de *Stanford University*; e a segunda, uma base com anotação manual, formada pela coletânea de dados disponibilizados anualmente entre 2013 e 2017 pelo *International Workshop on Semantic Evaluation* [3]. A análise de sentimento a ser aplicada terá seu enfoque na polaridade das mensagens, separando-as entre positivas e negativas. Não serão abordadas por esse projeto a objetividade ou neutralidade de um texto. Por fim, o modelo a ser obtido visa a classificação de mensagens escritas em língua inglesa.

1.3 Justificativa

Acompanhamos ao longo da última década a massificação do uso de redes sociais. O Twitter, objeto de nosso estudo, conta com 310 milhões de usuários ativos, gerando um total de meio bilhão de *tweets* por dia. Tais estatísticas provam ser cada vez mais necessário ferramentas capazes de automatizar o processo extração de informação deste mar de dados.

A análise de sentimento neste contexto visa resgatar opinião sobre um assunto, evento ou produto. Os primeiros estudos deste tópico aplicados ao Twitter foram desenvolvidos em 2009 por Go et al., [4]. Esse grupo de pesquisadores utiliza, em seu artigo, as melhores técnicas de classificação de texto disponíveis na época e ressalta as diferenças de seus resultados comparados a quando aplicadas em textos jornalísticos, resenhas etc.

O campo do processamento de linguagem natural foi fortemente impactado pelo crescimento do *Deep Learning*. Técnicas como Redes Neurais Convolutivas (CNN), a princípio desenvolvidas para processamento de imagens, e *Long Short-Term Memory* (LSTM) propulsionaram o salto de desempenho obtido nos últimos anos. O impacto deste avanço é notório no nosso dia-a-dia. Frequentemente utilizamos essas técnicas como em serviços automatizados de atendimento ao cliente ou em ferramentas de tradução simultânea.

Neste sentido, o presente projeto visa aplicar em *tweets* os procedimentos que compõe o estado da arte em classificação de sentimento.

1.4 Objetivos

O objetivo deste projeto, portanto, consiste em gerar um modelo computacional capaz de sistematizar a classificação de sentimento de *tweets*. Este modelo deve ser independente de uma base de dados anotada manualmente, visto o alto custo desta ser reproduzida.

1.5 Metodologia

Para alcançar esse objetivo, as seguintes etapas serão necessárias: (1) replicar técnicas consolidadas de análise de sentimento para *tweets* e utilizá-las como referência; (2) aplicar nos *tweets* técnicas de *Deep Learning* que vêm obtendo sucesso em processamento de linguagem natural.

A primeira etapa do trabalho será a replicação de estudos desenvolvidos por Go et al., [4] que aplica técnicas de *Naive Bayes* e *SVM* na classificação de polaridade de *tweets*, sendo seu treinamento feito em cima de uma base de dados com anotação automática, conforme apresentado por Read [5]. Os resultados obtidos por estas técnicas serão utilizados como patamar para comparação dos modelos a serem gerados.

Posteriormente, serão aplicadas técnicas de *Deep Learning*, como apresentadas por Kim [6], em que se utiliza CNNs para classificação de texto. O treinamento continua sendo feito a partir do banco de dados com anotação semi-supervisionada, o qual foi apresentado anteriormente. Será avaliado o desempenho desta técnica quando aplicada em mensagens do Twitter.

1.6 Descrição

No capítulo 2 será .....

O capítulo 3 apresenta ...

Os .... são apresentados no capítulo 4. Nele será explicitado ...

E assim vai até chegar na conclusão.

Capítulo 2

Posicionamento

2.1 Citação

Em um trabalho científico devemos ter sempre a preocupação de fazer referências precisas às idéias, frases ou conclusões de outros autores, isto é, citar a fonte (livro, revista e todo tipo de material produzido gráfica ou eletronicamente) de onde são extraídos esses dados. As citações fundamentam e melhoram a qualidade científica do trabalho, portanto, elas têm a função de oferecer ao leitor condições de comprovar a fonte das quais foram extraídas as idéias, frases ou conclusões, possibilitando-lhe ainda aprofundar o tema/assunto em discussão. Têm ainda como função, acrescentar indicações bibliográficas de reforço ao texto. Veja alguns exemplos:

É neste cenário que "[...] o desafiador cenário globalizado cumpre um papel essencial na formulação das formas de ação."[7].

Segundo Flávio Mello [8], "[...] é claro que o início da atividade geral de formação de atitudes prepara-nos para enfrentar situações atípicas decorrentes do sistema de formação de quadros que corresponde às necessidades [...]".

De acordo com Flávio Mello [9], a certificação de metodologias que nos auxiliam a lidar com o acompanhamento das preferências de consumo causa impacto indireto na reavaliação do orçamento setorial.

Figura 2.1: Logotipo do DEL. Fonte: DEL/Poli/UFRJ [1].

Por outro lado, a mobilidade dos capitais internacionais garante a contribuição de um grupo importante na determinação dos índices pretendidos. Percebemos, cada vez mais, que o novo modelo estrutural aqui preconizado deve passar por modificações independentemente das condições inegavelmente apropriadas [10].

Além disto, a expressão latina **apud** que significa: citado por, conforme, segundo é utilizada quando se faz referência a uma fonte secundária. Suponha que você teve acesso ao conteúdo do texto de Fulado através do trabalho Beltrano: Não obstante, a competitividade nas transações comerciais prepara-nos para enfrentar situações atípicas decorrentes do fluxo de informações. A determinação clara de objetivos garante a contribuição de um grupo importante na determinação dos relacionamentos verticais entre as hierarquias. O incentivo ao avanço tecnológico, assim como a mobilidade dos capitais internacionais desafia a capacidade de equalização de alternativas às soluções ortodoxas (Fulano [11] apud Beltrano [12]).

2.2 Figuras

Figuras (organogramas, fluxogramas, esquemas, desenhos, fotografias, gráficos, mapas, plantas e outros) constituem unidade autônoma e explicam, ou complementam visualmente o texto, portanto, devem ser inseridas o mais próximo possível do texto a que se referem. Sua identificação deverá aparecer na parte inferior precedida da palavra designativa (figura), seguida de seu número de ordem de ocorrência, do respectivo título e/ou legenda e da fonte, se necessário, tal como na Figura 2.1.

2.3 Tabelas

As tabelas são elementos demonstrativos de síntese que apresentam informações tratadas estatisticamente constituindo uma unidade autônoma. Em sua apresentação deve ser observado: (1) o título deverá ser colocado na parte inferior, precedido da palavra Tabela e de seu número de ordem; (2) as fontes e eventuais notas aparecem em seu rodapé, após o fechamento, utilizando-se o tamanho 10; (3) Devem ser inseridas o mais próximo possível do trecho a que se referem, tal como a Tabela 2.3.

Tabela 2.1: Casos de ataques aos computadores da Intranet. Fonte: DEL/Poli/UFRJ [1].

Número IP	**Ataques**	**Ataques bem sucedidos**
192.168.0.120	54	1
192.168.0.123	36	2
192.168.0.129	25	4
192.168.0.130	16	0
192.168.0.141	29	3
Total	**160**	**10**

2.4 Numeração de páginas

O aluno deve observar atentamente a numeração de páginas de seu projeto. A primeira parte deste modelo de projeto final, composta pela dedicatória, agradecimento, resumo, abstract, siglas, sumário, lista de figuras e lista de tabelas, é numerada seqüencialmente utilizando algarismos romanos minúsculos. As demais folhas, descritas na segunda parte deste modelo, são numeradas seqüencialmente utilizando algarismos arábicos.

Contudo, exclusivamente para a segunda parte do modelo de projeto, é permitida uma numeração alternativa na qual o aluno poderá numerar as páginas por capítulo. Por exemplo, a primeira página deste Capítulo 2 - Informações Adicionais, poderia ser escrita como 2.1. Além disto, a página seguinte seria 2.2 e a presente página poderia ser escrita como 2.3. A página do Apêndice A - O que é um apêndice,

poderia ser escrita como A.1, enquanto que a primeira página do apêndice B seria B.1. Neste caso alternativo específico, a Bibliografia na deverá conter numeração.

Capítulo 3

Aprendizado Supervisionado

O aprendizado supervisionado é o campo dentro de aprendizado de máquina que visa a gerar modelos preditores a partir de um conjunto de dados de treinamento cujos resultados são previamente conhecidos.

3.1 Naive Bayes

Naive Bayes é uma das técnicas mais simples disponíveis nesse contexto. Ela se baseia no teorema de Bayes enquanto assume independência entre as características escolhidas para descrever o dado. Abaixo veremos sua formulação matemática como descrita por Schütze [13].

Tendo $\mathbf{x}$ tal que $\mathbf{x} \in \mathbf{X}$ em que $\mathbf{X}$ é o conjunto de dados de treinamento, a sua probabilidade de pertencer a classe $c_k \in \mathbf{c}$ é dada pelo teorema de Bayes:

$$p(c_k \mid \mathbf{x}) = \frac{p(c_k)\ p(\mathbf{x} \mid c_k)}{p(\mathbf{x})} \tag{3.1}$$

Sendo $\mathbf{x}$ um vetor de n características, ao se assumir independência entre elas obtém-se:

$$p(x_i \mid x_{i+1}, \ldots, x_n, c_k) = p(x_i \mid c_k) \tag{3.2}$$

Logo, pode-se rescrever a equação 3.1 substituindo $p(\mathbf{x} \mid c_k)$ pelo produtório de suas características:

$$p(c_k \mid \mathbf{x}) = \frac{p(c_k) \prod_{i=1}^{n} p(x_i \mid c_k)}{p(\mathbf{x})} \tag{3.3}$$

Como $p(\mathbf{x})$ será uma constante dado cada exemplo $\mathbf{x}$ esta pode ser desprezada:

$$p(c_k \mid \mathbf{x}) \propto p(c_k) \prod_{i=1}^{n} p(x_i \mid c_k) \tag{3.4}$$

Portanto, tem-se que o estimador ótimo $\hat{y}$ escolherá pela classe que atinja maior probabilidade:

$$\hat{y} = \max_{k \in \{1,\ldots,K\}} p(c_k) \prod_{i=1}^{n} p(x_i \mid c_k) \tag{3.5}$$

Vê-se então que o modelo de *Naive Bayes* depende apenas de $p(c_k)$ e $p(\mathbf{x} \mid c_k)$. Estes parâmetros serão extraídos do conjunto de treino por máxima verosimilhança.

Dado um vetor $\mathbf{y}$ de tamanho m que representa as classificações referentes a $\mathbf{X}$, pode-se estimar $p(c_k)$ pela contagem de vezes que a classe c_k aparece no conjunto de treinamento:

$$\hat{p}(c_k) = \frac{\sum_{i=1}^{m} [y_i = c_k]}{m} \tag{3.6}$$

Por sua vez, $p(x_r \mid c_k)$ é estimado utilizando a contagem de vezes que uma característica aparece dividida pelo total de características presentes em $\mathbf{X}'$ que é o subconjunto de treino pertencente a classe c_k:

$$\hat{p}(x_r \mid c_k) = \frac{\sum_{j=i}^{m'} \sum_{i=1}^{n} [x_{ji} = x_r]}{|\mathbf{X}'|} \tag{3.7}$$

Vê-se que modelos montados a partir de *Naive Bayes* são computacionalmente baratos dado que seus parâmetros são obtidos através de contagens sobre os dados de treinamento e que sua predição utiliza apenas multiplicações. Embora se baseie na independência entre características, seu baixo custo operacional leva esta técnica a ser utilizada mesmo em problemas com notória dependência de características como a classificação de texto [14].

3.2 Support Vector Machine

O conceito fundamental do *Support Vector Machine* (SVM) se dá pela obtenção de um vetor de suporte que melhor separe as classes. Esta separação é feita de maneira que se maximize a margem entre as classes. A figura 3.1 demostra dados de duas classes distintas, representadas pelas cores rosa e amarelo, pertencentes a um espaço de características de duas dimensões; vê-se na figura que a reta que define a maior separação é suportada pelos dados de cada classe mais próximos a ela.

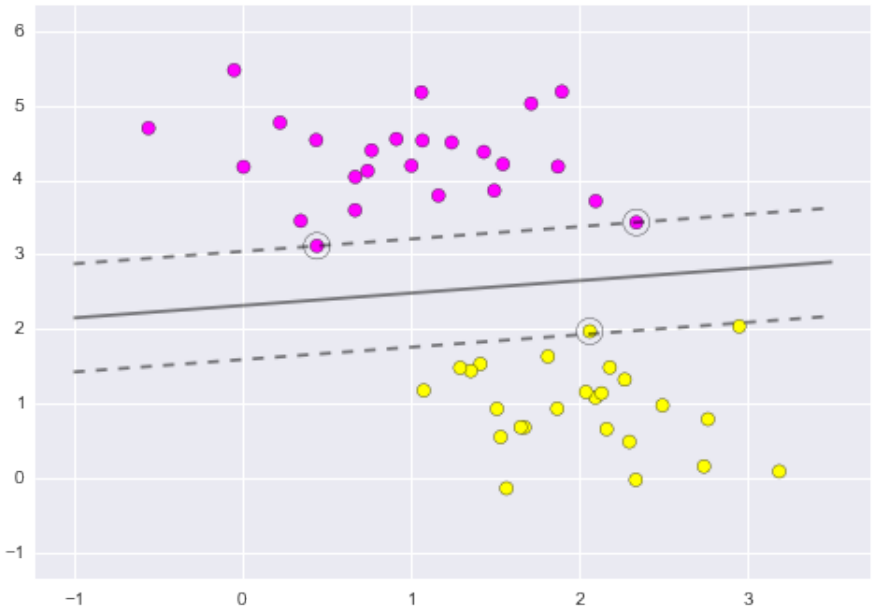

Figura 3.1: Reta de maior margem entre classes.
Imagem com direitos cedidos para uso não comercial, retirada de [15]

Por se basear nos dados próximos ao limiar de separação das classes, o algoritmo passa a ser incapaz de distinguir os casos de classes que não são separáveis sem erros. A solução desse problema foi a criação de uma variável de relaxamento que define um número máximo de erros de classificação permitido. Esta propriedade é descrita com mais detalhes por Cortes e Vapnik em [16]. Sua utilização permite o desenvolvimento de modelos mais robustos a *outliers* e melhora a generalização. Outros exemplos de regularizadores, como este, serão apresentados na subseção 3.6.

Como utilizam vetores de suporte para definir hiperplanos de separação, SVMs não são capazes de segregar classes não linearmente distinguíveis. Podemos observar um exemplo deste caso na figura 3.2, na qual um SVM treinado tenta separar classes concêntricas.

Para contornar esse impedimento, foi elaborado o que se chamou de *kernel trick*. Este se baseia em um mapeamento não linear dos dados para um espaço onde possam ser linearmente separáveis [17]. A figura 3.3 mostra a representação dos dados apresentados na figura 3.2 após seu mapeamento por uma função de base radial.

Neste novo espaço definido pela transformação, os dados são linearmente

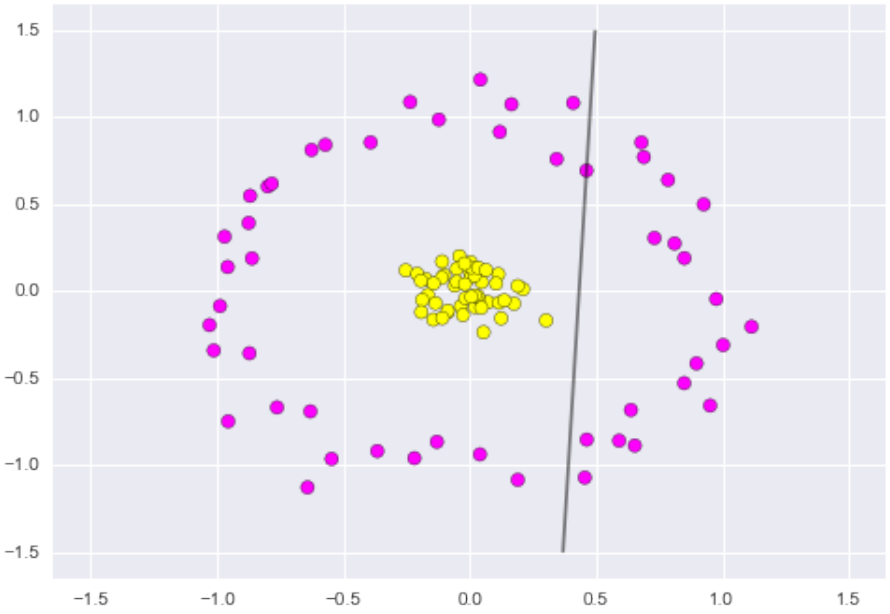

Figura 3.2: SVM em dados não linearmente separáveis.

Imagem com direitos cedidos para uso não comercial, retirada de [15]

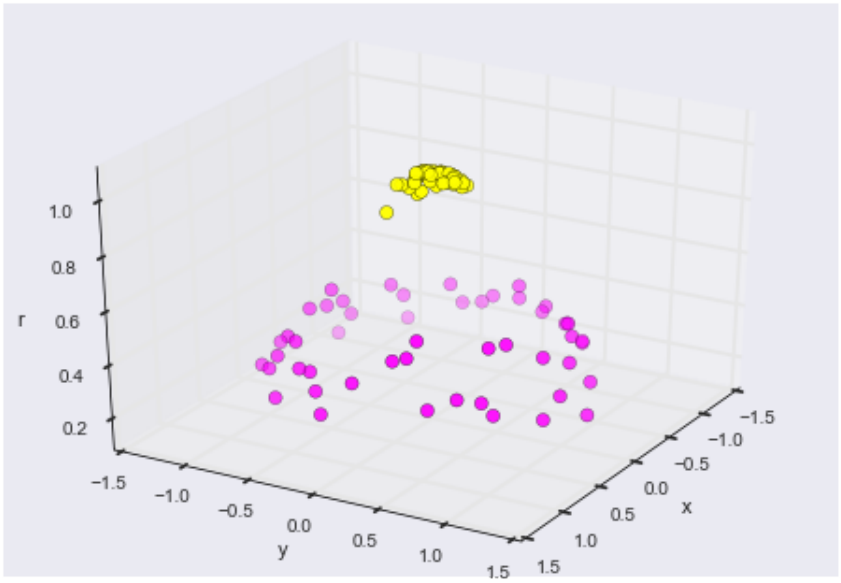

Figura 3.3: Transformação de dados por função de base radial.

Imagem com direitos cedidos para uso não comercial, retirada de [15]

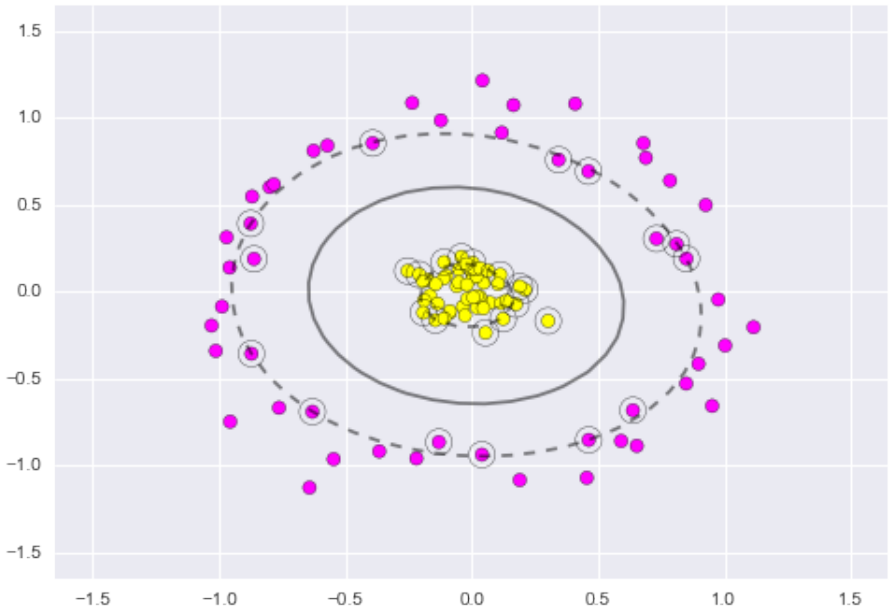

Figura 3.4: SVM com *kernel* de base radial.

Imagem com direitos cedidos para uso não comercial, retirada de [15]

separáveis. Portanto, é possível achar um vetor de suporte que defina um hiperplano de separação das classes. Vemos na figura 3.4 as margens encontradas.

Uma limitação na utilização deste algoritmo é seu tempo de treinamento. Sua complexidade computacional fica entre $O(n_{caracteristicas} \times n^2_{dados})$ e $O(n_{caracteristicas} \times n^3_{dados})$ [18]. Porém, Suykens e Vandewalle desenvolveram uma função custo através da qual tornou possível realizar o treinamento de SVMs a partir da otimização pelo método do gradiente [19].

3.3 Redes Neurais

redes neurais são sistemas computacionais que visam replicar o modelo de processamento do cérebro. Há diversas variações de redes neurais. Nesta subseção será abordada a mais simples, redes neurais feedforward, e na subseção 3.3.2 serão apresentadas redes neurais Convolucionais.

Redes neurais feedforward são compostas de camadas de neurônios sucessivamente interligadas por sinapses. As sinapses funcionam como um ponderador linear dos neurônios da camada anterior. Os neurônios, por sua vez, representam

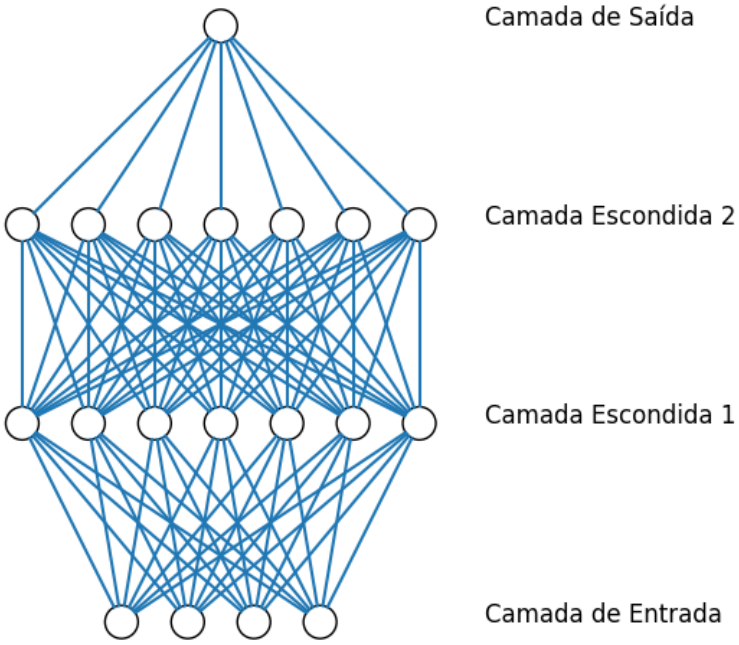

Figura 3.5: Rede Neural Feedforward

uma função de ativação, normalmente não linear, tais como: tangente hiperbólica, logística etc. Como exemplificação, há a figura 3.5, onde apresenta-se o diagrama de uma rede que conta com uma camada de entrada que representa os dados do problema, seguida de duas camadas intermediarias, comumente chamadas de escondidas, as quais são seguidas pela camada de saída, que apontará o resultado final de todo processamento da rede.

Uma de suas principais características de redes neurais é a capacidade de aproximar qualquer função, dado que a rede contenha pelo menos uma camada escondida com número suficientemente grande de neurônios com ativação não linear [20].

Para uma Rede Neural simular uma função, precisa-se obter o conjunto de pesos, ou sinapses, que torne esta rede uma boa representação para a função escolhida. Em outras palavras, precisa-se minimizar o erro da representação da rede dado que este erro é uma função das sinapses. Uma prática comum é inicializar a rede com pesos selecionados de uma distribuição uniforme com média zero e desvio padrão inversamente proporcional ao número de dados de treinamento [21]. Posteriormente, é feita uma otimização da representação em função dos pesos. Para

realizar esta otimização, utiliza-se normalmente *Backpropagation* para se encontrar o ajuste ideal de cada sinapse baseada, em sua contribuição no erro. Uma explicação deste método é apresentada por Williams e Hinton em [22].

3.3.1 Deep Learning

O sucesso na aplicação de redes neurais nas mais diversas áreas levou à utilização de redes cada vez mais robustas. Assim, redes neurais profundas romperam barreiras de performance em problemas como reconhecimento de fala, detecção de objetos, tradução etc [23]. Chamou-se de *Deep Learning* o campo de estudo de redes neurais com muitas camadas.

Cada camada de uma Rede Neural gera uma abstração que representa a sua entrada de modo a facilitar a tarefa a ser realizada. O encadeamento de camadas resulta em representações mais complexas dos dados, revelando relações previamente não observáveis. O aprofundamento das redes visa a reduzir ou eliminar a chamada *feature engineering*, processo de seleção de características, que usualmente requer expertise no domínio do problema. Considerando por exemplo o caso do diagnóstico de câncer de pele, técnicas tradicionais de classificação dependiam de extração de informações de imagens de lesões, tais como: formato, tamanho, cor etc. Modelos baseados em redes neurais profundas são capaz de obter resultados superiores, eliminando completamente esta etapa [24].

3.3.2 Redes Neurais Convolucionais

A utilização de redes neurais feedforward em imagens sofre limitações, por cada pixel estar diretamente ligado aos neurônios, rotações ou translações na imagem afetam fortemente a capacidade da rede. Pretendendo solucionar estes problemas, foram desenvolvidas redes neurais Convolucionais, cujas conexões são baseadas no funcionamento do córtex visual.

Elas são compostas primariamente de dois tipos de camadas: convolucionais e *pooling*. Camadas convolucionais são formadas por um conjunto de filtros espaciais compostos das mesmas funções não-lineares utilizadas em Redes feedforward [25]. Para cada exemplo do conjunto de dados, o filtro, cujo tamanho é menor que a entrada, é aplicado no inicio do dado e deslocado até o final. Desta forma, os

filtros dividem os pesos entre todo espaço do dado, permitindo uma insensibilidade a deslocamentos e rotações. Por sua vez, as camadas de *pooling* visam reduzir o número total de sinapses da rede. Para tal, reduz-se o tamanho dos filtros, obtendo-se valores máximos ou médias de dimensões desses filtros. *Pooling* é fundamental quando o objetivo a ser atingido depende mais da presença de uma característica do que sua sua posição no dado [25].

Por fim, apesar de Redes Convolucionais terem sido desenvolvidas com intuito de solucionar problemas de visão computacional, elas também obtiveram êxito nas mais diversas áreas, como no reconhecimento de voz e em séries temporais [26]. Tal sucesso pode ser atribuído à insensibilidade da rede a deslocamentos.

3.4 Funções Custo

Dá-se o nome de *função custo* às funções que caracterizam a distância entre o resultado obtido pela rede e seu objetivo. Assim, as sinapses de redes neurais são otimizadas a partir da minimização de tais funções. Nesta seção, serão apresentadas as funções custo mais relevantes no contexto de redes neurais.

3.4.1 Erro Médio Quadrático

A função custo mais utilizada é o erro médio quadrático (EMQ). Seu fator quadrático pune mais severamente grandes erros, acelerando o processo de otimização.

A fórmula 3.8 mostra a composição do EMQ sendo n o número de pares de exemplos e $\hat{y}$ a predição da rede neural.

$$\frac{\sum^{n} |\hat{\mathbf{y}}_i - \mathbf{y}_i|^2}{n} \tag{3.8}$$

3.4.2 Erro Médio Absoluto

O erro médio absoluto se assemelha ao EMQ, tendo como diferença a falta do fator quadrático, conforme observa-se na fórmula 3.9.

$$\frac{\sum^{n} |\hat{\mathbf{y}}_i - \mathbf{y}_i|}{n} \tag{3.9}$$

3.4.3 Erro Médio Absoluto Percentual

Há situações em que se pretende mapear um objetivo com extensão de diferentes ordens de grandeza. O uso de erro médio quadrático ou absoluto nestes casos irá dar menos relevância a entradas pequenas. Para solucionar este problema, o erro médio absoluto percentual é composto conforme apresentado na fórmula 3.10

$$\frac{100}{n} \sum^{n} \left| \frac{\hat{\mathbf{y}}_i - \mathbf{y}_i}{\mathbf{y}_i} \right| \tag{3.10}$$

3.4.4 Entropia Cruzada

A entropia cruzada é uma medida que contém a distância entre duas distribuições de probabilidades. Sua formula é disposta de maneira que sua otimização encontre os parâmetros de máxima verossimilhança. As equações 3.11 e 3.12 mostram a dedução da função de verossimilhança $\mathcal{L}$ a partir da probabilidade a posteriori, na qual k representa cada classe presente no conjunto de dados.

$$\mathcal{L}(\theta) = \prod_k P(\mathbf{y}_k \mid \mathbf{x}) \tag{3.11}$$

$$\mathcal{L}(\theta) = \prod_k \hat{\mathbf{y}}_k^{\mathbf{y}_k} (1 - \hat{\mathbf{y}}_k)^{(1-\mathbf{y}_k)} \tag{3.12}$$

Para simplificar o custo computacional, o valor máximo da função verossimilhança é obtido minimizando-se o negativo de seu logaritmo, como presente na fórmula 3.13.

$$-\ln(\mathcal{L}(\theta)) = -\sum_k \mathbf{y}_k \ln(\hat{\mathbf{y}}_k) + (1 - \mathbf{y}_k) \ln(1 - \hat{\mathbf{y}}_k) \tag{3.13}$$

A expressão 3.14 mostra o uso da entropia cruzada como função custo. A segunda parte do somatório determina que a acurácia de não classe pode ser ignorada para determinada classe k, visto que esta já será considerada na sua classe correta. É necessário notar que a sua utilização depende de $\mathbf{y}_i$ e $\hat{\mathbf{y}}_i$ serem limitados entre

0 e 1. Para adequar-se a esta limitação, caso a rede neural possua apenas uma saída, utiliza-se ativação Sigmoid na última camada. Em caso de múltiplas saídas, utiliza-se ativação Softmax.

$$\frac{-\sum^{n}\sum_{k}\mathbf{y}_k \ln(\hat{\mathbf{y}}_k)}{n} \tag{3.14}$$

3.5 Otimizadores

Definidas as funções custo, nesta seção serão abordados os algoritmos responsáveis por sua minimização. Embora a área de otimização apresente uma vasta gama de opções, sua utilização em aprendizado de máquina costuma se restringir a algoritmos de primeira ordem, como o gradiente descendente, principalmente por seu menor custo computacional. O método do gradiente, primeiramente apresentado por Cauchy em 1847 [27], consiste em minimizar a função custo por meio de atualizações iterativas de parâmetros do modelo, a partir da derivada da própria função custo em relação aos parâmetros.

Redes neurais, em geral, possuem funções custo não convexas. Assim sendo, o algoritmo de gradiente descendente não garante convergência ao mínimo global. A convergência a mínimos locais torna o modelo sensível a parâmetros, como funções de ativação, número de neurônios, etc., e o torna sensível também à inicialização dos pesos, como mostra Glorot no artigo em que apresenta um método de inicialização de pesos homônimo [28]. Entretanto, o problema de convergência não se limita a mínimos locais. Dauphin [29] mostra que quanto maior o número de variáveis latentes do modelo, maior a proporção de pontos de sela em relação a mínimos locais. Mostra também que os mínimos locais estão mais propensos a aparecer em pontos críticos com baixo custo, enquanto pontos de sela costumam aparecer em pontos de alto custo. Goodfellow [30] apresenta resultados empíricos da efetividade do método do gradiente na fuga dos pontos de sela.

O algoritmo 1 descreve a forma tradicional do gradiente descendente, dado que L é a função custo adotada e que $\hat{\mathbf{y}}$ é o mapeamento obtido pela rede neural a partir dos dados $\mathbf{x}$ e pesos $\boldsymbol{\theta}$. Observa-se que $\hat{\mathbf{g}}$ é a estimativa do gradiente dos pesos obtida a partir dos dados de treinamento.

Algoritmo 1 Gradiente Descendente

Parâmetro Taxa de treinamento ϵ

Parâmetro Pesos iniciais $\boldsymbol{\theta}_0$

Parâmetro Número de iterações T

$t \leftarrow 0$

while $t < T$ **do**

$t \leftarrow t + 1$

$\hat{\mathbf{y}} \leftarrow f(\mathbf{x}, \boldsymbol{\theta}_{t-1})$

$\hat{\mathbf{g}} \leftarrow \frac{1}{n} \nabla_{\boldsymbol{\theta}} \sum_i^n L(\hat{\mathbf{y}}^{(i)}, \mathbf{y}^{(i)})$

$\boldsymbol{\theta}_t \leftarrow \boldsymbol{\theta}_{t-1} - \epsilon \hat{\mathbf{g}}$

end while

Serão apresentadas nas próximas subseções as variações do método do gradiente mais notórias no treinamento de redes neurais.

3.5.1 Gradiente Descendente Estocástico

A forma canônica do algoritmo do gradiente descendente começa a apresentar dificuldades de utilização em conjuntos de dados de tamanho considerável. Como observa-se no algoritmo 1, para cada atualização dos pesos $\boldsymbol{\theta}$ é necessária a estimação do gradiente $\hat{\mathbf{g}}$, a qual, por sua vez, depende da computação da função custo sobre todos os dados. Além do alto custo computacional, bases de dados grandes tendem a conter várias instâncias de dados muito próximos, não adicionando significativamente informação à estimação do gradiente.

Uma das soluções deste problema, abordada pelo *Gradiente Descendente Estocástico*, é a divisão do conjunto de treinamento em lotes, nos quais serão estimados os gradientes. Cada interação sobre o conjunto inteiro de dados é chamada de época e entre cada época costuma-se embaralhar os dados. Já as outras partes do algoritmo permanecem iguais à implementação tradicional como apresentado em 1.

3.5.2 Gradiente Descendente com Momento

A escolha da taxa de treinamento envolve uma troca entre tempo de treinamento e grau de convergência. Altas taxas de treinamento podem apresentar difi-

culdades de convergência ou comportamentos oscilatórios em torno de um ponto de custo mínimo, enquanto baixas taxas de treinamento consomem muito tempo de treinamento em regiões de alto custo, diminuindo assim sua viabilidade. Objetivando-se obter um melhor compromisso, foi acrescentado o momento ao método do gradiente, como formulado no algoritmo 2. O termo adicional $\mathbf{v}$ representa a "velocidade"do gradiente e a constante de momento α condiz com a taxa de decaimento exponencial do termo $\mathbf{v}$.

Algoritmo 2 Gradiente Descendente com Momento

Parâmetro Taxa de treinamento ϵ

Parâmetro Constante de momento α

Parâmetro Pesos iniciais $\boldsymbol{\theta}_0$

Parâmetro Número de iterações T

$t \leftarrow 0$

$\mathbf{v}_0 \leftarrow \vec{0}$

while $t < T$ **do**

$t \leftarrow t + 1$

$\hat{\mathbf{y}} \leftarrow f(\mathbf{x}, \boldsymbol{\theta}_{t-1})$

$\hat{\mathbf{g}} \leftarrow \frac{1}{n} \nabla_{\boldsymbol{\theta}} \sum_i^n L(\hat{\mathbf{y}}^{(i)}, \mathbf{y}^{(i)})$

$\mathbf{v}_t \leftarrow \alpha \mathbf{v}_{t-1} - \epsilon \hat{\mathbf{g}}$

$\boldsymbol{\theta}_t \leftarrow \boldsymbol{\theta}_{t-1} + \mathbf{v}_t$

end while

O momento permite que, enquanto o gradiente $\hat{\mathbf{g}}$ mantiver o mesmo sinal entre iterações, o módulo da velocidade $\mathbf{v}$ cresça, acelerando o processo de aprendizado. Quando o sinal do gradiente for invertido, ou seja, passar de um ponto de custo mínimo, o módulo da velocidade será reduzido até seu sentido ser revertido, voltando ao mínimo. Segundo Haykin [31], o uso do momento tem um efeito estabilizador no algoritmo de aprendizado.

3.5.3 Adam

Outra abordagem adotada nos algoritmos de otimização é o ajuste da taxa de aprendizado de maneira independente para cada dimensão do espaço. Duchi *et al.*

[32] propuseram o algoritmo *AdaGrad* (*Adaptative Gradient*), no qual a regra de atualização dos pesos é inversamente proporcional à soma do gradiente ao quadrado em todas iterações anteriores. Dessa forma, direções que tenham grandes e frequentes atualizações serão amortecidas rapidamente, enquanto dimensões com raras atualizações mantêm seu treinamento significativo por mais iterações. Algoritmos com taxa de treinamento adaptativo, como o proposto por Duchi *et al.*, atingem bons resultados em problemas com dimensões esparsas, como o exemplo de Pennington *et al.* [33] no treinamento de *embeddings* de palavras, técnica que será apresentada na seção 4.2.2.

Kingma e Ba [34] projetaram o algoritmo *Adam adaptative moment estimation* baseado nos princípios do *AdaGrad*. *Adam* estima o primeiro e segundo momentos do gradiente, média e variância não centralizada, a partir da média móvel de ambos. A regra de atualização de pesos é controlada pela taxa de treinamento ϵ, e pelas estimativas de média e variância, $\hat{\mathbf{m}}$ e $\hat{\mathbf{v}}$ respectivamente, dada a fórmula $\boldsymbol{\theta}_t \leftarrow \boldsymbol{\theta}_{t-1} - \epsilon \frac{\hat{\mathbf{m}}_t}{\sqrt{\hat{\mathbf{v}}_t}}$. Portanto, gradientes grandes por seguidas iterações aumentam a média e, por consequência, o tamanho do passo. Por sua vez, altas variâncias forçam a diminuição da taxa efetiva de aprendizado.

O algoritmo 3 possui a implementação de *Adam* em pseudocódigo. Os valores dos decaimentos betas costumam ser escolhidos em torno de 0.9 para β_1 e 0.999 para β_2. Pelos momentos serem inicializados em zero, é necessário corrigir a tendência para se obter a verdadeira estimativa.

Adam apresenta robustez à escolha da taxa de treinamento ϵ, visto que esta funciona como um limite superior da taxa efetiva de atualização dos pesos, como provado em seu artigo [34], juntamente com sua análise de convergência e com seus resultados experimentais. Por se utilizar de médias móveis na estimação dos momentos, o algoritmo apresenta outra vantagem, sua capacidade de se adaptar a funções objetivos não estacionárias.

Por sua robustez à escolha de hiperparametros e por sua aceleração do processo de aprendizado *Adam* se tornou uma das principais técnicas de otimização de redes neurais profundas.

Algoritmo 3 Adam

Parâmetro Taxa de treinamento ϵ

Parâmetro Constante de decaimento β_1, β_2

Parâmetro Pesos iniciais $\boldsymbol{\theta}_0$

Parâmetro Número de iterações T

$t \leftarrow 0$

$\mathbf{m}_0 \leftarrow \vec{0}$

$\mathbf{v}_0 \leftarrow \vec{0}$

while $t < T$ **do**

$t \leftarrow t + 1$

$\hat{\mathbf{y}} \leftarrow f(\mathbf{x}, \boldsymbol{\theta}_{t-1})$

$\hat{\mathbf{g}} \leftarrow \frac{1}{n} \nabla_{\boldsymbol{\theta}} \sum_i^n L(\hat{\mathbf{y}}^{(i)}, \mathbf{y}^{(i)})$

$\mathbf{m}_t \leftarrow \beta_1 \mathbf{m}_{t-1} + (1 - \beta_1)\hat{\mathbf{g}}$

$\mathbf{v}_t \leftarrow \beta_2 \mathbf{v}_{t-1} + (1 - \beta_2)\hat{\mathbf{g}}^2$

$\hat{\mathbf{m}}_t \leftarrow \frac{\mathbf{m}_t}{(1-\beta_1^t)}$

$\hat{\mathbf{v}}_t \leftarrow \frac{\mathbf{v}_t}{(1-\beta_2^t)}$

$\boldsymbol{\theta}_t \leftarrow \boldsymbol{\theta}_{t-1} - \epsilon \frac{\hat{\mathbf{m}}_t}{\sqrt{\hat{\mathbf{v}}_t}}$

end while

3.6 Generalização

Um dos principais fatores de um sistema de aprendizado de maquina é sua capacidade de generalizar, isto é, quando seu desempenho em dados de teste, ou seja, dados que não foram utilizados na fase de treinamento, é equivalente ou suficientemente próximo ao obtido durante aprendizado.

A fase de aprendizado do sistema pode ser vista como o processo de ajuste de parâmetros. Desta forma, ao tentar representar a função, o modelo pode sofrer com sobreajuste, *overfitting*, adequando-se demais aos dados de treinamento. O oposto também acontece quando o modelo é incapaz de mapear a complexidade entre as entradas e a saída; a este evento dá-se o nome de subajuste, *underfit*. Tais eventos estão exemplificados na figura 3.6.

O uso de modelos robustos como os de *Deep Learning* implica em uma maior propensão de se obter *overfitting* durante o treinamento, resultado de seu crescente número de parâmetros livres. Abordando esse problema, foi desenvolvido um conjunto de técnicas que visam a reduzir o *overfitting*, conjunto esse que recebe o nome de regularização. Nas subseções seguintes serão apresentadas as duas principais técnicas de regularização.

3.6.1 Regularização de Tikhonov

As regularizações de norma compõem um dos grupos mais simples de regularização. Seu funcionamento é possível pois se adiciona à função custo um termo proporcional aos pesos, penalizando neurônios com grandes normas. Assim, limita-se a capacidade do modelo e, consequentemente, diminui-se o potencial de *overfitting*.

Também conhecida como regularização L_2, a regularização de Tikhonov utiliza-se da norma quadrática dos pesos. A formula 3.15 exemplifica a função custo erro médio quadrático com o termo adicional de regularização L_2, que por sua vez é controlado por uma constante λ.

$$\frac{\sum^{n} |\hat{\mathbf{y}}_i - \mathbf{y}_i|^2}{n} + \frac{\lambda}{2}\|\boldsymbol{\theta}\|_2^2 \tag{3.15}$$

Krogh e Hertz [35] provam que o uso de regularização L_2 é capaz de suprimir parâmetros irrelevantes, diminuindo o número de parâmetros do modelo, e de reduzir

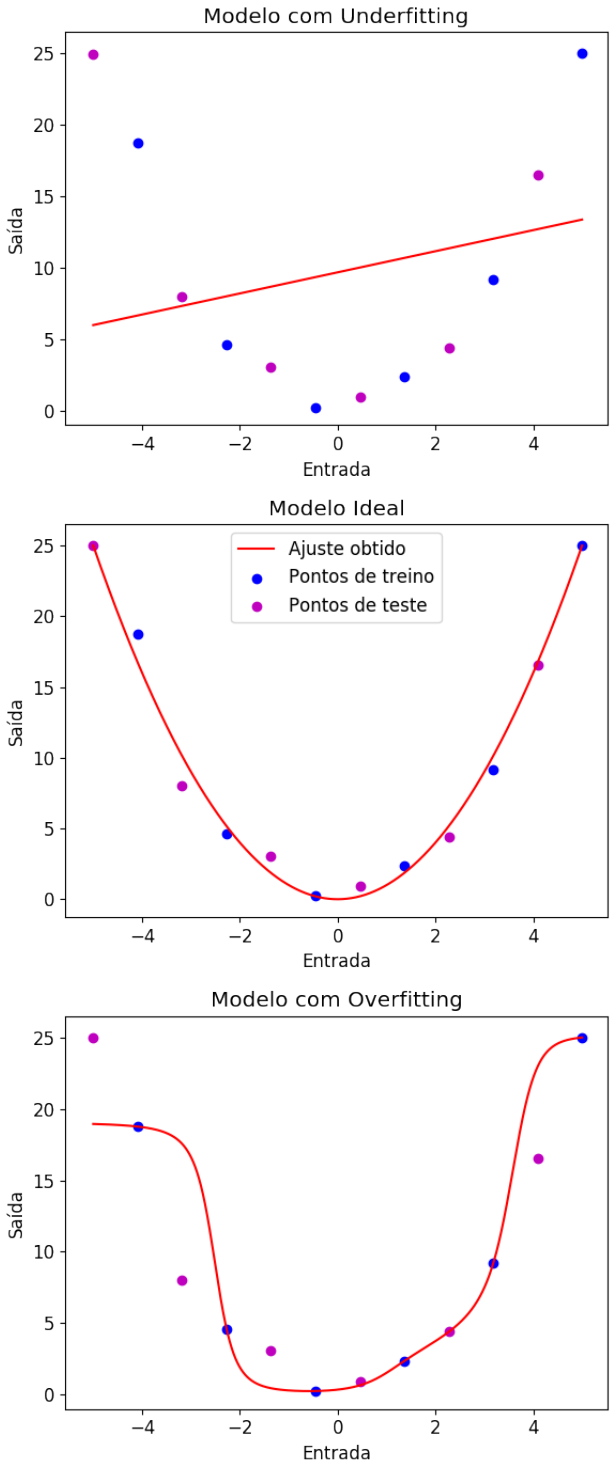

Figura 3.6: Diferentes pontos de ajuste.

o efeito de ruídos presentes na anotação dos dados.

3.6.2 Dropout

Apresentado por Srivastava *et al.* [36], *Dropout* é um método que propõe reduzir o *overfitting* por meio de desligar aleatóriamente neurônios durante a etapa de treinamento. Inspirado na reprodução sexuada, que envolve trocas entre genes de dois individuos distintos, Srivastava *et al.* acreditam que assim como na evolução biológica, técnicas que reduzam a co-adaptação entre neuronios tornam redes neurais mais resistentes a destruição de informação, fazendo com que cada neuronio extraia caracteristicas relevantes por si só, aumentando a redundantes e melhorando assim o desempenho da rede como um todo.

Trabalhos anteriores [37] mostram que a combinação de modelos com diferentes parâmetros, também conhecidos como *ensembling*, quase sempre resulta em uma melhora na eficiência sobre a utilização de um modelo isoladamente. Porém, no escopo de *Deep Learning*,

Dropout

3.7 Supervisão Distante

Capítulo 4

Processamento de Linguagem Natural

4.1 Pré-Processamentos

4.2 Representações Numéricas

4.2.1 One-Hot

4.2.2 Word2Vec

Capítulo 5

Metodologia

Capítulo 6

Resultados

Capítulo 7

Conclusões

Tratam-se das considerações finais do trabalho, mostrando que os objetivos foram cumpridos e enfatizando as descobertas feitas durante o projeto. Em geral reserva-se um ou dois parágrafos para sugerir trabalhos futuros.

Observe que neste modelo a conclusão é numerada pelo numeral 3, mas o projeto não tem a obrigatoriedade de possuir apenas 3 capítulos. Alias, espera-se que tenha mais que isso.

Referências Bibliográficas

[1] MEYER, D. E., KIERAS, D. E., *Título da nota tecnica*, Report TR-97/ONR-EPIC-08, Department of Psychology, Electrical Engineering & computer Science Department, University of Michigan, 1997.

[2] "Sentiment140 - A Twitter Sentiment Analysis Tool", `http://www.sentiment140.com/`, acessado em 28 de Maio 2017.

[3] "International Workshop on Semantic Evaluation 2017", `http://alt.qcri.org/semeval2017/`, acessado em 28 de Maio 2017.

[4] GO, A., BHAYANI, R., HUANG, L., "Twitter sentiment classification using distant supervision", *CS224N Project Report, Stanford*, v. 1, n. 12, 2009.

[5] READ, J., "Using emoticons to reduce dependency in machine learning techniques for sentiment classification". In: *Proceedings of the ACL student research workshop*, pp. 43–48, Association for Computational Linguistics, 2005.

[6] KIM, Y., "Convolutional neural networks for sentence classification", *arXiv preprint arXiv:1408.5882*, , 2014.

[7] LEWIS, H. R., PAPADIMITRIOU, C. H., *Título do livro*. Porto Alegre, Bookman, 2004.

[8] NETTLE, P., "Título da URL", http://www.brainvoyager.com/, 2006, (Acesso em 05 Janeiro 2006).

[9] HEEGER, D., RESS, D., "Título do artigo", *Nature Reviews/Neuroscience*, v. 3, pp. 142–151, 2002.

[10] CANGUILHEM, G., "Título do artigo em proceeding". In: *Georges Canguilhem - Philosophe, historien des sciences: Actes du Colloque*, pp. 11–33, Paris, 1993.

[11] FULANO, J., *Título da dissertação de mestrado*. M.Sc. dissertation, Universidade Federal do Rio de Janeiro, Julho 2003.

[12] BELTRANO, M., *Título do livro onde se consultou um capítulo*, chapter Membrane potential and action potential, New York, Academic Press, pp. 129–154, 1999.

[13] SCHÜTZE, H., "Introduction to information retrieval". In: *Proceedings of the international communication of association for computing machinery conference*, 2008.

[14] MCCALLUM, A., NIGAM, K., OTHERS, "A comparison of event models for naive bayes text classification". Citeseer.

[15] VANDERPLAS, J., `https://github.com/jakevdp/sklearn_pycon2015/blob/master/notebooks/03.1-Classification-SVMs.ipynb`, acessado em 28 de Maio 2017.

[16] CORTES, C., VAPNIK, V., "Support-vector networks", *Machine Learning*, v. 20, n. 3, pp. 273–297, 1995.

[17] SCHÖLKOPF, B., SMOLA, A., "Support Vector Machines and Kernel Algorithms", 2002.

[18] LIST, N., SIMON, H. U., "SVM-optimization and steepest-descent line search". In: *Proceedings of the 22nd Annual Conference on Computational Learning Theory*, 2009.

[19] SUYKENS, J. A., VANDEWALLE, J., "Least squares support vector machine classifiers", *Neural processing letters*, v. 9, n. 3, pp. 293–300, 1999.

[20] HORNIK, K., STINCHCOMBE, M., WHITE, H., "Multilayer feedforward networks are universal approximators", *Neural networks*, v. 2, n. 5, pp. 359–366, 1989.

[21] LECUN, Y. A., BOTTOU, L., ORR, G. B., *et al.*, "Efficient backprop". In: *Neural networks: Tricks of the trade*, Springer, pp. 9–48, 2012.

[22] WILLIAMS, D., HINTON, G., "Learning representations by back-propagating errors", *Nature*, v. 323, n. 6088, pp. 533–538, 1986.

[23] LECUN, Y., BENGIO, Y., HINTON, G., "Deep learning", *Nature*, v. 521, n. 7553, pp. 436–444, 2015.

[24] ESTEVA, A., KUPREL, B., NOVOA, R. A., *et al.*, "Dermatologist-level classification of skin cancer with deep neural networks", *Nature*, v. 542, n. 7639, pp. 115–118, 2017.

[25] GOODFELLOW, I., BENGIO, Y., COURVILLE, A., *Deep Learning*. MIT Press, 2016. `http://www.deeplearningbook.org`.

[26] LECUN, Y., BENGIO, Y., OTHERS, "Convolutional networks for images, speech, and time series", *The handbook of brain theory and neural networks*, v. 3361, n. 10, 1995.

[27] CAUCHY, A., "Méthode générale pour la résolution des systemes d'équations simultanées", *Comp. Rend. Sci. Paris*, v. 25, n. 1847, pp. 536–538, 1847.

[28] GLOROT, X., BENGIO, Y., "Understanding the difficulty of training deep feedforward neural networks". In: *Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics*, pp. 249–256, 2010.

[29] DAUPHIN, Y. N., PASCANU, R., GULCEHRE, C., *et al.*, "Identifying and attacking the saddle point problem in high-dimensional non-convex optimization". In: *Advances in neural information processing systems*, pp. 2933–2941, 2014.

[30] GOODFELLOW, I. J., VINYALS, O., SAXE, A. M., "Qualitatively characterizing neural network optimization problems", *arXiv preprint arXiv:1412.6544*, , 2014.

[31] HAYKIN, S., *Neural networks and learning machines*, v. 3. Pearson Upper Saddle River, NJ, USA:, 2009.

[32] DUCHI, J., HAZAN, E., SINGER, Y., "Adaptive subgradient methods for online learning and stochastic optimization", *Journal of Machine Learning Research*, v. 12, n. Jul, pp. 2121–2159, 2011.

[33] PENNINGTON, J., SOCHER, R., MANNING, C., "Glove: Global vectors for word representation". In: *Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP)*, pp. 1532–1543, 2014.

[34] KINGMA, D., BA, J., "Adam: A method for stochastic optimization", *arXiv preprint arXiv:1412.6980*, , 2014.

[35] KROGH, A., HERTZ, J. A., "A simple weight decay can improve generalization". In: *Advances in neural information processing systems*, pp. 950–957, 1992.

[36] SRIVASTAVA, N., HINTON, G. E., KRIZHEVSKY, A., *et al.*, "Dropout: a simple way to prevent neural networks from overfitting.", *Journal of machine learning research*, v. 15, n. 1, pp. 1929–1958, 2014.

[37] DIETTERICH, T. G., OTHERS, "Ensemble methods in machine learning", *Multiple classifier systems*, v. 1857, pp. 1–15, 2000.

Apêndice A

O que é um apêndice

Elemento que consiste em um texto ou documento elaborado pelo autor, com o intuito de complementar sua argumentação, sem prejuízo do trabalho. São identificados por letras maiúsculas consecutivas e pelos respectivos títulos.

Apêndice B

Encadernação do Projeto de Graduação

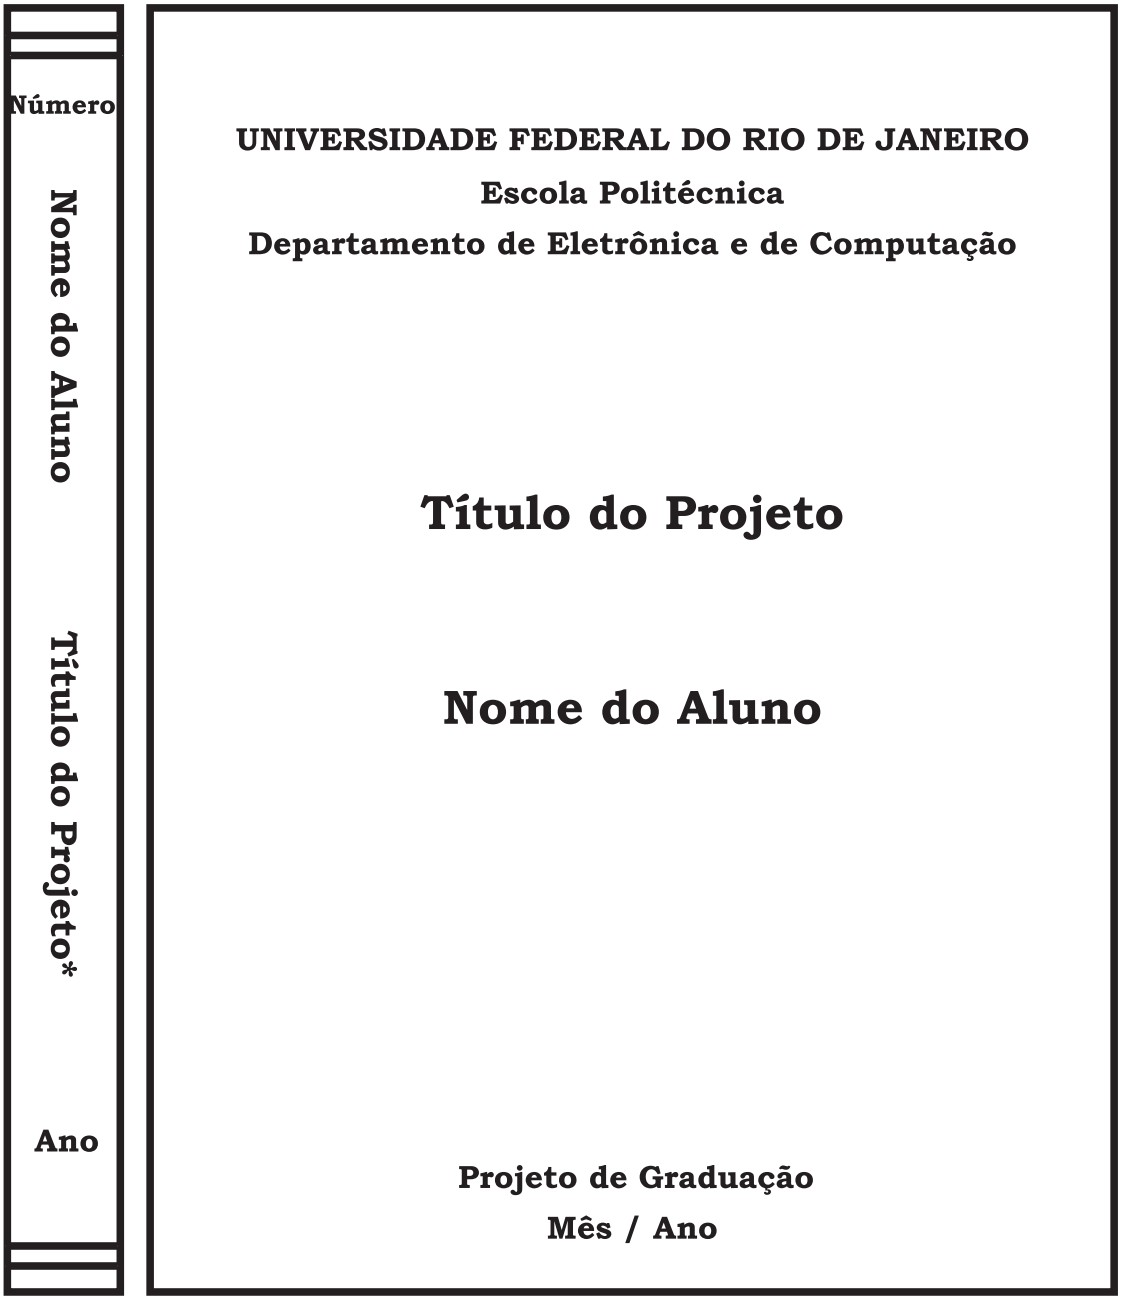

*** Título resumido caso necessário**
Capa na cor preta, inscrições em dourado

Figura B.1: Encadernação do projeto de graduação.

Apêndice C

O que é um anexo

Documentação não elaborada pelo autor, ou elaborada pelo autor mas constituindo parte de outro projeto.