



Universidade Federal  
do Rio de Janeiro  

---

Escola Politécnica

## APRENDIZADO SEMI-SUPERVISIONADO PARA CLASSIFICAÇÃO DE POLARIDADE DE TWEETS

Breno Vieira Arosa

Projeto de Graduação apresentado ao Curso de Engenharia Eletrônica e de Computação da Escola Politécnica, Universidade Federal do Rio de Janeiro, como parte dos requisitos necessários à obtenção do título de Engenheiro.

Orientador: Luiz Pereira Calôba

Rio de Janeiro  
Julho de 2017

# APRENDIZADO SEMI-SUPERVISIONADO PARA CLASSIFICAÇÃO DE POLARIDADE DE TWEETS

Breno Vieira Arosa

PROJETO DE GRADUAÇÃO SUBMETIDO AO CORPO DOCENTE DO CURSO  
DE ENGENHARIA ELETRÔNICA E DE COMPUTAÇÃO DA ESCOLA PO-  
LITÉCNICA DA UNIVERSIDADE FEDERAL DO RIO DE JANEIRO COMO  
PARTE DOS REQUISITOS NECESSÁRIOS PARA A OBTENÇÃO DO GRAU  
DE ENGENHEIRO ELETRÔNICO E DE COMPUTAÇÃO

Autor:

---

Breno Vieira Arosa

Orientador:

---

Prof. Luiz Pereira Calôba, Dr. Ing.

Examinador:

---

Prof Frances Elizabeth Allen, D. Sc.

Examinador:

---

Prof. Alan Jay Perlis, D. E.

Rio de Janeiro

Julho de 2017

## Declaração de Autoria e de Direitos

Eu, *Breno Vieira Arosa* CPF 131.187.117-95, autor da monografia *Aprendizado Semi-Supervisionado para Classificação de Polaridade de Tweets*, subscrevo para os devidos fins, as seguintes informações:

1. O autor declara que o trabalho apresentado na disciplina de Projeto de Graduação da Escola Politécnica da UFRJ é de sua autoria, sendo original em forma e conteúdo.
2. Excetua-se do item 1. eventuais transcrições de texto, figuras, tabelas, conceitos e idéias, que identifiquem claramente a fonte original, explicitando as autorizações obtidas dos respectivos proprietários, quando necessárias.
3. O autor permite que a UFRJ, por um prazo indeterminado, efetue em qualquer mídia de divulgação, a publicação do trabalho acadêmico em sua totalidade, ou em parte. Essa autorização não envolve ônus de qualquer natureza à UFRJ, ou aos seus representantes.
4. O autor pode, excepcionalmente, encaminhar à Comissão de Projeto de Graduação, a não divulgação do material, por um prazo máximo de 01 (um) ano, improrrogável, a contar da data de defesa, desde que o pedido seja justificado, e solicitado antecipadamente, por escrito, à Congregação da Escola Politécnica.
5. O autor declara, ainda, ter a capacidade jurídica para a prática do presente ato, assim como ter conhecimento do teor da presente Declaração, estando ciente das sanções e punições legais, no que tange a cópia parcial, ou total, de obra intelectual, o que se configura como violação do direito autoral previsto no Código Penal Brasileiro no art.184 e art.299, bem como na Lei 9.610.
6. O autor é o único responsável pelo conteúdo apresentado nos trabalhos acadêmicos publicados, não cabendo à UFRJ, aos seus representantes, ou ao(s) orientador(es), qualquer responsabilização/ indenização nesse sentido.
7. Por ser verdade, firmo a presente declaração.

---

Breno Vieira Arosa

UNIVERSIDADE FEDERAL DO RIO DE JANEIRO

Escola Politécnica - Departamento de Eletrônica e de Computação

Centro de Tecnologia, bloco H, sala H-217, Cidade Universitária

Rio de Janeiro - RJ CEP 21949-900

Este exemplar é de propriedade da Universidade Federal do Rio de Janeiro, que poderá incluí-lo em base de dados, armazenar em computador, microfilmear ou adotar qualquer forma de arquivamento.

É permitida a menção, reprodução parcial ou integral e a transmissão entre bibliotecas deste trabalho, sem modificação de seu texto, em qualquer meio que esteja ou venha a ser fixado, para pesquisa acadêmica, comentários e citações, desde que sem finalidade comercial e que seja feita a referência bibliográfica completa.

Os conceitos expressos neste trabalho são de responsabilidade do(s) autor(es).

## DEDICATÓRIA

Opcional.

## AGRADECIMENTO

Sempre haverá. Se não estiver inspirado, aqui está uma sugestão: dedico este trabalho ao povo brasileiro que contribuiu de forma significativa à minha formação e estada nesta Universidade. Este projeto é uma pequena forma de retribuir o investimento e confiança em mim depositados.

## **RESUMO**

Inserir o resumo do seu trabalho aqui. O objetivo é apresentar ao pretense leitor do seu Projeto Final uma descrição genérica do seu trabalho. Você também deve tentar despertar no leitor o interesse pelo conteúdo deste documento.

Palavras-Chave: trabalho, resumo, interesse, projeto final.

## ABSTRACT

Insert your abstract here. Insert your abstract here. Insert your abstract here.  
Insert your abstract here. Insert your abstract here.

Key-words: word, word, word.



## SIGLAS

SVM - *Support Vector Machine*

UFRJ - Universidade Federal do Rio de Janeiro

WYSIWYG - *What you see is what you get*

# Sumário

<b>1</b>	<b>Introdução</b>	<b>1</b>
1.1	Tema . . . . .	1
1.2	Delimitação . . . . .	1
1.3	Justificativa . . . . .	2
1.4	Objetivos . . . . .	2
1.5	Metodologia . . . . .	3
1.6	Descrição . . . . .	3
<b>2</b>	<b>Posicionamento</b>	<b>4</b>
2.1	Citação . . . . .	4
2.2	Figuras . . . . .	5
2.3	Tabelas . . . . .	6
2.4	Numeração de páginas . . . . .	6
<b>3</b>	<b>Aprendizado Supervisionado</b>	<b>8</b>
3.1	Naive Bayes . . . . .	8
3.2	SVM . . . . .	9
3.3	Redes Neurais . . . . .	12
3.3.1	Deep Learning . . . . .	14
3.3.2	Redes Neurais Convolucionais . . . . .	14
3.4	Otimizadores . . . . .	14
3.4.1	SGD . . . . .	14
3.4.2	Momentum . . . . .	14
3.4.3	RMSProp . . . . .	14
3.4.4	Adam . . . . .	14

3.5	Regularizadores . . . . .	14
3.5.1	L2 . . . . .	14
3.5.2	Dropout . . . . .	14
3.6	Supervisão Distante . . . . .	14
<b>4</b>	<b>Processamento de Linguagem Natural</b>	<b>15</b>
4.1	Tokenizer . . . . .	15
4.2	Representações Matemáticas . . . . .	15
4.2.1	One-Hot . . . . .	15
4.2.2	Word2Vec . . . . .	15
<b>5</b>	<b>Metodologia</b>	<b>16</b>
<b>6</b>	<b>Resultados</b>	<b>17</b>
<b>7</b>	<b>Conclusões</b>	<b>18</b>
	<b>Bibliografia</b>	<b>19</b>
<b>A</b>	<b>O que é um apêndice</b>	<b>21</b>
<b>B</b>	<b>Encadernação do Projeto de Graduação</b>	<b>22</b>
<b>C</b>	<b>O que é um anexo</b>	<b>24</b>

# Lista de Figuras

2.1	Logotipo do DEL. Fonte: DEL/Poli/UFRJ [1]. . . . .	5
3.1	Reta de maior margem entre classes. . . . .	10
3.2	SVM em dados não linearmente separáveis. . . . .	11
3.3	Transformação de dados por função de base radial. . . . .	11
3.4	SVM com <i>kernel</i> de base radial. . . . .	12
3.5	Rede Neural FeedFoward . . . . .	13
B.1	Encadernação do projeto de graduação. . . . .	23

# Lista de Tabelas

2.1	Casos de ataques aos computadores da Intranet. Fonte: DEL/Poli/UFRJ	
	[1]. . . . .	6

# Capítulo 1

## Introdução

### 1.1 Tema

O tema do projeto é o estudo de técnicas de aprendizado de máquina para classificação de sentimento em mensagens de redes sociais, em especial o Twitter. Portanto, o projeto visa criar um modelo capaz de distinguir entre a polaridade, positiva ou negativa, de uma mensagem.

### 1.2 Delimitação

O objeto de estudo são *tweets*, mensagens publicadas no Twitter. Serão utilizadas duas bases de dados: a primeira, uma base anotada automaticamente pelo *Sentiment140* [2], o qual é formado por um grupo de alunos de *Stanford University*; e a segunda, uma base com anotação manual, formada pela coletânea de dados disponibilizados anualmente entre 2013 e 2017 pelo *International Workshop on Semantic Evaluation* [3]. A análise de sentimento a ser aplicada terá seu enfoque na polaridade das mensagens, separando-as entre positivas e negativas. Não serão abordadas por esse projeto a objetividade ou neutralidade de um texto. Por fim, o modelo a ser obtido visa a classificação de mensagens escritas em língua inglesa.

## 1.3 Justificativa

Acompanhamos ao longo da última década a massificação do uso de redes sociais. O Twitter, objeto de nosso estudo, conta com 310 milhões de usuários ativos, gerando um total de meio bilhão de *tweets* por dia. Tais estatísticas provam ser cada vez mais necessário ferramentas capazes de automatizar o processo extração de informação deste mar de dados.

A análise de sentimento neste contexto visa resgatar opinião sobre um assunto, evento ou produto. Os primeiros estudos deste tópico aplicados ao Twitter foram desenvolvidos em 2009 por Go et al., [4]. Esse grupo de pesquisadores utiliza, em seu artigo, as melhores técnicas de classificação de texto disponíveis na época e ressalta as diferenças de seus resultados comparados a quando aplicadas em textos jornalísticos, resenhas etc.

O campo do processamento de linguagem natural foi fortemente impactado pelo crescimento do *Deep Learning*. Técnicas como Redes Neurais Convolutivas (CNN), a princípio desenvolvidas para processamento de imagens, e *Long Short-Term Memory* (LSTM) propulsionaram o salto de desempenho obtido nos últimos anos. O impacto deste avanço é notório no nosso dia-a-dia. Frequentemente utilizamos essas técnicas como em serviços automatizados de atendimento ao cliente ou em ferramentas de tradução simultânea.

Neste sentido, o presente projeto visa aplicar em *tweets* os procedimentos que compõe o estado da arte em classificação de sentimento.

## 1.4 Objetivos

O objetivo deste projeto, portanto, consiste em gerar um modelo computacional capaz de sistematizar a classificação de sentimento de *tweets*. Este modelo deve ser independente de uma base de dados anotada manualmente, visto o alto custo desta ser reproduzida.

## 1.5 Metodologia

Para alcançar esse objetivo, as seguintes etapas serão necessárias: (1) replicar técnicas consolidadas de análise de sentimento para *tweets* e utilizá-las como referência; (2) aplicar nos *tweets* técnicas de *Deep Learning* que vêm obtendo sucesso em processamento de linguagem natural.

A primeira etapa do trabalho será a replicação de estudos desenvolvidos por Go et al., [4] que aplica técnicas de *Naive Bayes* e *SVM* na classificação de polaridade de *tweets*, sendo seu treinamento feito em cima de uma base de dados com anotação automática, conforme apresentado por Read [5]. Os resultados obtidos por estas técnicas serão utilizados como patamar para comparação dos modelos a serem gerados.

Posteriormente, serão aplicadas técnicas de *Deep Learning*, como apresentadas por Kim [6], em que se utiliza CNNs para classificação de texto. O treinamento continua sendo feito a partir do banco de dados com anotação semi-supervisionada, o qual foi apresentado anteriormente. Será avaliado o desempenho desta técnica quando aplicada em mensagens do Twitter.

## 1.6 Descrição

No capítulo 2 será .....

O capítulo 3 apresenta ...

Os .... são apresentados no capítulo 4. Nele será explicitado ...

E assim vai até chegar na conclusão.



# Capítulo 2

## Posicionamento

### 2.1 Citação

Em um trabalho científico devemos ter sempre a preocupação de fazer referências precisas às idéias, frases ou conclusões de outros autores, isto é, citar a fonte (livro, revista e todo tipo de material produzido gráfica ou eletronicamente) de onde são extraídos esses dados. As citações fundamentam e melhoram a qualidade científica do trabalho, portanto, elas têm a função de oferecer ao leitor condições de comprovar a fonte das quais foram extraídas as idéias, frases ou conclusões, possibilitando-lhe ainda aprofundar o tema/assunto em discussão. Têm ainda como função, acrescentar indicações bibliográficas de reforço ao texto. Veja alguns exemplos:

É neste cenário que "[...] o desafiador cenário globalizado cumpre um papel essencial na formulação das formas de ação." [7].

Segundo Flávio Mello [8], "[...] é claro que o início da atividade geral de formação de atitudes prepara-nos para enfrentar situações atípicas decorrentes do sistema de formação de quadros que corresponde às necessidades [...]".

De acordo com Flávio Mello [9], a certificação de metodologias que nos auxiliam a lidar com o acompanhamento das preferências de consumo causa impacto indireto na reavaliação do orçamento setorial.



Figura 2.1: Logotipo do DEL. Fonte: DEL/Poli/UFRJ [1].

Por outro lado, a mobilidade dos capitais internacionais garante a contribuição de um grupo importante na determinação dos índices pretendidos. Percebemos, cada vez mais, que o novo modelo estrutural aqui preconizado deve passar por modificações independentemente das condições inegavelmente apropriadas [10].

Além disto, a expressão latina **apud** que significa: citado por, conforme, segundo é utilizada quando se faz referência a uma fonte secundária. Suponha que você teve acesso ao conteúdo do texto de Fulado através do trabalho Beltrano: Não obstante, a competitividade nas transações comerciais prepara-nos para enfrentar situações atípicas decorrentes do fluxo de informações. A determinação clara de objetivos garante a contribuição de um grupo importante na determinação dos relacionamentos verticais entre as hierarquias. O incentivo ao avanço tecnológico, assim como a mobilidade dos capitais internacionais desafia a capacidade de equalização de alternativas às soluções ortodoxas (Fulano [11] apud Beltrano [12]).

## 2.2 Figuras

Figuras (organogramas, fluxogramas, esquemas, desenhos, fotografias, gráficos, mapas, plantas e outros) constituem unidade autônoma e explicam, ou complementam visualmente o texto, portanto, devem ser inseridas o mais próximo possível do texto a que se referem. Sua identificação deverá aparecer na parte inferior precedida da palavra designativa (figura), seguida de seu número de ordem de ocorrência, do respectivo título e/ou legenda e da fonte, se necessário, tal como na Figura 2.1.

## 2.3 Tabelas

As tabelas são elementos demonstrativos de síntese que apresentam informações tratadas estatisticamente constituindo uma unidade autônoma. Em sua apresentação deve ser observado: (1) o título deverá ser colocado na parte inferior, precedido da palavra Tabela e de seu número de ordem; (2) as fontes e eventuais notas aparecem em seu rodapé, após o fechamento, utilizando-se o tamanho 10; (3) Devem ser inseridas o mais próximo possível do trecho a que se referem, tal como a Tabela 2.3.

Tabela 2.1: Casos de ataques aos computadores da Intranet. Fonte: DEL/Poli/UFRJ [1].

Número IP	Ataques	Ataques bem sucedidos
192.168.0.120	54	1
192.168.0.123	36	2
192.168.0.129	25	4
192.168.0.130	16	0
192.168.0.141	29	3
<b>Total</b>	<b>160</b>	<b>10</b>

## 2.4 Numeração de páginas

O aluno deve observar atentamente a numeração de páginas de seu projeto. A primeira parte deste modelo de projeto final, composta pela dedicatória, agradecimento, resumo, abstract, siglas, sumário, lista de figuras e lista de tabelas, é numerada sequencialmente utilizando algarismos romanos minúsculos. As demais folhas, descritas na segunda parte deste modelo, são numeradas sequencialmente utilizando algarismos arábicos.

Contudo, exclusivamente para a segunda parte do modelo de projeto, é permitida uma numeração alternativa na qual o aluno poderá numerar as páginas por capítulo. Por exemplo, a primeira página deste Capítulo 2 - Informações Adicionais, poderia ser escrita como 2.1. Além disto, a página seguinte seria 2.2 e a presente página poderia ser escrita como 2.3. A página do Apêndice A - O que é um apêndice,

poderia ser escrita como A.1, enquanto que a primeira página do apêndice B seria B.1. Neste caso alternativo específico, a Bibliografia na deverá conter numeração.

# Capítulo 3

## Aprendizado Supervisionado

O aprendizado supervisionado é o campo dentro de aprendizado de máquina que visa a gerar modelos preditores a partir de um conjunto de dados de treinamento cujos resultados são previamente conhecidos.

### 3.1 Naive Bayes

*Naive Bayes* é uma das técnicas mais simples disponíveis nesse contexto. Ela se baseia no teorema de Bayes enquanto assume independência entre as características escolhidas para descrever o dado. Abaixo veremos sua formulação matemática como descrita por Schütze [13].

Tendo  $\mathbf{x}$  tal que  $\mathbf{x} \in \mathbf{X}$  em que  $\mathbf{X}$  é o conjunto de dados de treinamento, a sua probabilidade de pertencer a classe  $c_k \in \mathbf{c}$  é dada pelo teorema de Bayes:

$$p(c_k | \mathbf{x}) = \frac{p(c_k) p(\mathbf{x} | c_k)}{p(\mathbf{x})} \quad (3.1)$$

Sendo  $\mathbf{x}$  um vetor de  $n$  características, ao se assumir independência entre elas obtém-se:

$$p(x_i | x_{i+1}, \dots, x_n, c_k) = p(x_i | c_k) \quad (3.2)$$

Logo, pode-se rescrever a equação 3.1 substituindo  $p(\mathbf{x} | c_k)$  pelo produtório de suas características:

$$p(c_k | \mathbf{x}) = \frac{p(c_k) \prod_{i=1}^n p(x_i | c_k)}{p(\mathbf{x})} \quad (3.3)$$

Como  $p(\mathbf{x})$  será uma constante dado cada exemplo  $\mathbf{x}$  esta pode ser desprezada:

$$p(c_k | \mathbf{x}) \propto p(c_k) \prod_{i=1}^n p(x_i | c_k) \quad (3.4)$$

Portanto, tem-se que o estimador ótimo  $\hat{y}$  escolherá pela classe que atinja maior probabilidade:

$$\hat{y} = \max_{k \in \{1, \dots, K\}} p(c_k) \prod_{i=1}^n p(x_i | c_k) \quad (3.5)$$

Vê-se então que o modelo de *Naive Bayes* depende apenas de  $p(c_k)$  e  $p(\mathbf{x} | c_k)$ . Estes parâmetros serão extraídos do conjunto de treino por máxima verosimilhança.

Dado um vetor  $\mathbf{y}$  de tamanho  $m$  que representa as classificações referentes a  $\mathbf{X}$ , pode-se estimar  $p(c_k)$  pela contagem de vezes que a classe  $c_k$  aparece no conjunto de treinamento:

$$\hat{p}(c_k) = \frac{\sum_{i=1}^m [y_i = c_k]}{m} \quad (3.6)$$

Por sua vez,  $p(x_r | c_k)$  é estimado utilizando a contagem de vezes que uma característica aparece dividida pelo total de características presentes em  $\mathbf{X}'$  que é o subconjunto de treino pertencente a classe  $c_k$ :

$$\hat{p}(x_r | c_k) = \frac{\sum_{j=i}^{m'} \sum_{i=1}^n [x_{ji} = x_r]}{|\mathbf{X}'|} \quad (3.7)$$

Vê-se que modelos montados a partir de *Naive Bayes* são computacionalmente baratos dado que seus parâmetros são obtidos através de contagens sobre os dados de treinamento e que sua predição utiliza apenas multiplicações. Embora se baseie na independência entre características, seu baixo custo operacional leva esta técnica a ser utilizada mesmo em problemas com notória dependência de características como a classificação de texto [14].

## 3.2 SVM

O conceito fundamental do *Support Vector Machine* se dá pela obtenção de um vetor de suporte que melhor separe as classes. Esta separação é feita de maneira que se maximize a margem entre as classes. A figura 3.1 demonstra dados de duas classes distintas, representadas pelas cores rosa e amarelo, pertencentes a um espaço de características de duas dimensões; vê-se na figura que a reta que define a maior separação é suportada pelos dados de cada classe mais próximos a ela.




Figura 3.1: Reta de maior margem entre classes.

Imagem com direitos cedidos para uso não comercial, retirada de [15]

Por se basear nos dados próximos ao limiar de separação das classes, o algoritmo passa a ser incapaz de distinguir os casos de classes que não são separáveis sem erros. A solução desse problema foi a criação de uma variável de relaxamento que define um número máximo de erros de classificação permitido. Esta propriedade é descrita com mais detalhes por Cortes e Vapnik em [16]. Sua utilização permite o desenvolvimento de modelos mais robustos a *outliers* e melhora a generalização. Outros exemplos de regularizadores, como este, serão apresentados na subseção 3.5.

Como utilizam vetores de suporte para definir hiperplanos de separação, SVMs não são capazes de segregar classes não linearmente distinguíveis. Podemos observar um exemplo deste caso na figura 3.2, na qual um SVM treinado tenta separar classes concêntricas.

Para contornar esse impedimento, foi elaborado o que se chamou de *kernel trick*. Este se baseia em um mapeamento não linear dos dados para um espaço onde possam ser linearmente separáveis [17]. A figura 3.3 mostra a representação dos dados apresentados na figura 3.2 após seu mapeamento por uma função de base radial.

Neste novo espaço definido pela transformação, os dados são linearmente




Figura 3.2: SVM em dados não linearmente separáveis.

Imagem com direitos cedidos para uso não comercial, retirada de [15]




Figura 3.3: Transformação de dados por função de base radial.

Imagem com direitos cedidos para uso não comercial, retirada de [15]






Figura 3.4: SVM com *kernel* de base radial.

Imagem com direitos cedidos para uso não comercial, retirada de [15]

separáveis. Portanto, é possível achar um vetor de suporte que defina um hiperplano de separação das classes. Vemos na figura 3.4 as margens encontradas.

Uma limitação na utilização deste algoritmo é seu tempo de treinamento. Sua complexidade computacional fica entre  $O(n_{caracteristicas} \times n_{dados}^2)$  e  $O(n_{caracteristicas} \times n_{dados}^3)$  [18]. Porém, Suykens e Vandewalle desenvolveram uma função custo através da qual tornou possível realizar o treinamento de SVMs a partir da otimização pelo método do gradiente [19].

### 3.3 Redes Neurais

Redes Neurais são sistemas computacionais que visam replicar o modelo de processamento do cérebro. Há diversas variações de Redes Neurais, nesta subseção será abordada a mais simples, Redes Neurais FeedForward, e na subseção 3.3.2 serão apresentadas Redes Neurais Convolucionais.

Redes Neurais FeedForward são compostas de camadas de neurônios sucessivamente interligadas por sinapses. As sinapses funcionam como um ponderador linear dos neurônios da camada anterior. Os neurônios, por sua vez, representam




Figura 3.5: Rede Neural FeedForward

uma função de ativação, normalmente não linear, tais como: tangente hiperbólica, logística, etc. Como exemplificação, há a figura 3.5, onde apresenta-se o diagrama de uma rede que conta com uma camada de entrada que representa os dados do problema, seguida de duas camadas intermediárias, comumente chamadas de escondidas, as quais são seguidas pela camada de saída, que apontará o resultado final de todo processamento da rede.

Uma de suas principais características de Redes Neurais é a capacidade de aproximar qualquer função, dado que a rede contenha pelo menos uma camada escondida com número suficientemente grande de neurônios com ativação não linear [20].

Para se simular uma função desejada por Rede Neural precisa-se obter o conjunto de pesos, ou sinapses, que torne esta rede em uma boa representação para a função escolhida. Ou seja, precisa-se minimizar o erro da representação da rede dado que este erro é uma função das sinapses. Uma prática comum é inicializar a rede com pesos selecionados de uma distribuição uniforme com média zero e desvio padrão inversamente proporcional ao número de dados de treinamento [21].

### **3.3.1 Deep Learning**

### **3.3.2 Redes Neurais Convolucionais**

## **3.4 Otimizadores**

### **3.4.1 SGD**

### **3.4.2 Momentum**

### **3.4.3 RMSProp**

### **3.4.4 Adam**

## **3.5 Regularizadores**

### **3.5.1 L2**

### **3.5.2 Dropout**

## **3.6 Supervisão Distante**

# Capítulo 4

## Processamento de Linguagem Natural

### 4.1 Tokenizer

### 4.2 Representações Matemáticas

#### 4.2.1 One-Hot

#### 4.2.2 Word2Vec

# Capítulo 5

## Metodologia

## Capítulo 6

## Resultados

# Capítulo 7

## Conclusões

Tratam-se das considerações finais do trabalho, mostrando que os objetivos foram cumpridos e enfatizando as descobertas feitas durante o projeto. Em geral reserva-se um ou dois parágrafos para sugerir trabalhos futuros.

Observe que neste modelo a conclusão é numerada pelo numeral 3, mas o projeto não tem a obrigatoriedade de possuir apenas 3 capítulos. Alias, espera-se que tenha mais que isso.

# Referências Bibliográficas

- [1] MEYER, D. E., KIERAS, D. E., *Título da nota tecnica*, Report TR-97/ONR-EPIC-08, Department of Psychology, Electrical Engineering & computer Science Department, University of Michigan, 1997.
- [2] “Sentiment140 - A Twitter Sentiment Analysis Tool”, <http://www.sentiment140.com/>, acessado em 28 Maio 2017.
- [3] “International Workshop on Semantic Evaluation 2017”, <http://alt.qcri.org/semeval2017/>, acessado em 28 Maio 2017.
- [4] GO, A., BHAYANI, R., HUANG, L., “Twitter sentiment classification using distant supervision”, *CS224N Project Report, Stanford*, v. 1, n. 12, 2009.
- [5] READ, J., “Using emoticons to reduce dependency in machine learning techniques for sentiment classification”. In: *Proceedings of the ACL student research workshop*, pp. 43–48, Association for Computational Linguistics, 2005.
- [6] KIM, Y., “Convolutional neural networks for sentence classification”, *arXiv preprint arXiv:1408.5882*, , 2014.
- [7] LEWIS, H. R., PAPADIMITRIOU, C. H., *Título do livro*. Porto Alegre, Bookman, 2004.
- [8] NETTLE, P., “Título da URL”, <http://www.brainvoyager.com/>, 2006, (Acesso em 05 Janeiro 2006).
- [9] HEEGER, D., RESS, D., “Título do artigo”, *Nature Reviews/Neuroscience*, v. 3, pp. 142–151, 2002.
- [10] CANGUILHEM, G., “Título do artigo em proceeding”. In: *Georges Canguilhem - Philosophe, historien des sciences: Actes du Colloque*, pp. 11–33, Paris, 1993.



- [11] FULANO, J., *Título da dissertação de mestrado*. M.Sc. dissertation, Universidade Federal do Rio de Janeiro, Julho 2003.
- [12] BELTRANO, M., *Título do livro onde se consultou um capítulo*, chapter Membrane potential and action potential, New York, Academic Press, pp. 129–154, 1999.
- [13] SCHÜTZE, H., “Introduction to information retrieval”. In: *Proceedings of the international communication of association for computing machinery conference*, 2008.
- [14] MCCALLUM, A., NIGAM, K., OTHERS, “A comparison of event models for naive bayes text classification”. Citeseer.
- [15] VANDERPLAS, J., [https://github.com/jakevdp/sklearn\\_pycon2015/blob/master/notebooks/03.1-Classification-SVMs.ipynb](https://github.com/jakevdp/sklearn_pycon2015/blob/master/notebooks/03.1-Classification-SVMs.ipynb), acessado em 28 Maio 2017.
- [16] CORTES, C., VAPNIK, V., “Support-vector networks”, *Machine Learning*, v. 20, n. 3, pp. 273–297, 1995.
- [17] SCHÖLKOPF, B., SMOLA, A., “Support Vector Machines and Kernel Algorithms”, 2002.
- [18] LIST, N., SIMON, H. U., “SVM-optimization and steepest-descent line search”. In: *Proceedings of the 22nd Annual Conference on Computational Learning Theory*, 2009.
- [19] SUYKENS, J. A., VANDEWALLE, J., “Least squares support vector machine classifiers”, *Neural processing letters*, v. 9, n. 3, pp. 293–300, 1999.
- [20] HORNIK, K., STINCHCOMBE, M., WHITE, H., “Multilayer feedforward networks are universal approximators”, *Neural networks*, v. 2, n. 5, pp. 359–366, 1989.
- [21] LECUN, Y. A., BOTTOU, L., ORR, G. B., *et al.*, “Efficient backprop”. In: *Neural networks: Tricks of the trade*, Springer, pp. 9–48, 2012.

# Apêndice A

## O que é um apêndice

Elemento que consiste em um texto ou documento elaborado pelo autor, com o intuito de complementar sua argumentação, sem prejuízo do trabalho. São identificados por letras maiúsculas consecutivas e pelos respectivos títulos.

## Apêndice B

# Encadernação do Projeto de Graduação

Número	<p><b>UNIVERSIDADE FEDERAL DO RIO DE JANEIRO</b></p> <p><b>Escola Politécnica</b></p> <p><b>Departamento de Eletrônica e de Computação</b></p>
Nome do Aluno	
Título do Projeto*	<p><b>Título do Projeto</b></p> <p><b>Nome do Aluno</b></p>
Ano	<p><b>Projeto de Graduação</b></p> <p><b>Mês / Ano</b></p>

**\* Título resumido caso necessário**  
**Capa na cor preta, inscrições em dourado**

Figura B.1: Encadernação do projeto de graduação.

# Apêndice C

## O que é um anexo

Documentação não elaborada pelo autor, ou elaborada pelo autor mas constituindo parte de outro projeto.